

**SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
VARAŽDIN**

Stjepan Marić

INFORMACIJSKI SUSTAV ZA FANTASY NOGOMETNU LIGU

PROJEKTNI ZADATAK

Varaždin, 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Stjepan Marić

Matični broj: 0016166230

Studij: Informacijski i poslovni sustavi

Kolegij: Baze Podataka 2

INFORMACIJSKI SUSTAV ZA FANTASY NOGOMETNU LIGU

PROJEKTNI RAD

Mentor/Mentorica:

Maja Cerjan, mag. educ. inf.

Varaždin, siječanj 2026

Stjepan Marić

Izjava o izvornosti

Izjavljujem da je moj projektni rad izvorni rezultat mog rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Autor potvrdio prihvatanjem odredbi u sustavu Moodle

Sažetak

Ovaj projekt bavi se izradom modela baze podataka za sustav upravljanja fantasy nogometnom ligom FIFA Club World Cupa korištenjem PostgreSQL sustava. Teorijsko-metodološka podloga temelji se na relacijskom modelu podataka i ERA pristupu modeliranju. Cilj ovog projekta je dizajn i implementacija baze podataka koja omogućava korisnicima formiranje virtualnih timova nogometaša, praćenje statistike te bodovanje istih na temelju stvarnih rezultata. ERA model sadrži deset međusobno povezanih tablica koje prikazuju ključne entitete sustava. Sam projekt primjenjuje okidače koji služe za automatsko izračunavanje bodova igrača te praćenje promjena u sustavu. Osim toga, koristeći Python Tkinter biblioteku omogućene su osnovne operacije dodavanja, uređivanja i brisanja podataka. Upiti različite složenosti ukazuju na mogućnosti analize podataka kroz spajanje tablica i agregacijske funkcije. Završni sustav pokazuje uspješnu automatizaciju bodovanja i upravljanje ligom te pruža korisnicima jednostavno sučelje za korištenje.

Ključne riječi: baza podataka; PostgreSQL; ERA model; fantasy football; okidači; Python; SQL upit

Sadržaj

1. Uvod	1
2. Opis korištenih alata i tehnologija	2
2.1 Draw.io	2
2.2 PostgreSQL i DataGrip	2
2.3 Python Tkinter.....	2
3. Opis aplikacijske domene	3
4. Prikaz i razrada ERA modela	4
5. Primjer upita i okidača	5
5.1 Jednostavni upiti.....	5
5.1.1 Prvi primjer jednostavnog upita	5
5.1.2 Drugi primjer jednostavnog upita	5
5.1.3 Treći primjer jednostavnog upita	6
5.2 Složeni upiti.....	6
5.2.1 Prvi primjer složenog upita	6
5.2.2 Drugi primjer složenog upita.....	7
5.2.3 Treći primjer složenog upita	7
5.3 Okidači	8
5.3.1 Prvi primjer okidača	8
5.3.2 Drugi primjer okidača	8
6. Prikaz funkcionalnosti razvijenog sučelja.....	9
7. Zaključak	11

1. Uvod

Tema projektnog zadatka je razvoj informacijskog sustava za upravljanje fantasy nogometnom ligom. Sam projekt obuhvaća izradu ERA modela, implementaciju u PostgreSQL te razvoj korisničkog sučelja uz pomoć Pythona. Kroz korisničko sučelje korisnici mogu dodavati nove igrače, pregledati dostupne nogometaše, zamjenjivati postojeće članove ekipe te ih i uklanjati. Način bodovanja dodjeljuje se na temelju njihovih izvedbi u stvarnim utakmicama.

Odabrana tema omogućava praktičnu primjenu koncepta baze podataka na realnom problemu koji danas koriste milijuni korisnika. Fantasy sportske platforme predstavljaju primjer web sustava kojim korisnik upravlja vlastitim timom, odabirom igrača i praćenjem njihovih rezultata.

Motivacija za odabir teme proizlazi iz osobnog interesa za nogomet i želje za praktičnom primjenom znanja stečenog tijekom studija. Kao korisnik „Fantasy liga“, uvidio sam vrijednost razumijevanja tehničke pozadine u stvarnom svijetu. Samim time, projekt predstavlja kombinaciju domenskog znanja iz sporta s tehničkim vještinama.

2. Opis korištenih alata i tehnologija

Za modeliranje i implementaciju informacijskog sustava za Fantasy nogometnu ligu korišteni su: draw.io, PostgreSQL i Python Tkinter. Svaki od alata korišten je u svojoj domeni. Draw.io je korišten za dizajniranje ERA modela, dok je PostgreSQL služio kao sustav za upravljanje bazom uz pomoć razvojnog okruženja DataGrip. Isto tako, Python Tkinter je korišten u svrhu izrade formi i korisničkog sučelja.

2.1 Draw.io

Draw.io je besplatan alat za izradu raznovrsnih dijagrama koji uključuju ERD, UML, dijagram toka i druge. Jednostavnost korištenja i bogata biblioteka oblika, stilova i simbola nudi visoku razinu prilagodbe u načinu modeliranja baze podataka. Također, podržava izvoz dijagrama u različitim formatima (PNG, JPEG, SVG) i integraciju s cloud poslužiteljima. U ovom projektu draw.io je korišten u svrhu izrade ERA dijagrama za „Fantasy nogometnu ligu“.

2.2 PostgreSQL i DataGrip

1.1. PostgreSQL je sustav za upravljanje bazama podataka otvorenog koda. Kao sustav omogućava rad s velikim količinama podataka te podržava različite tipove podataka. Nadalje, DataGrip je integrirano razvojno sučelje tvrtke JetBrains namijenjeno radu s bazama podataka. Omogućuje preglednije pisanje i izvršavanje SQL naredbi te podržava brojne baze podataka, uključujući MySQL, Oracle, PostgreSQL i druge. DataGrip je u ovom projektu korišten za izradu, testiranje i upravljanje strukturom same baze.

2.3 Python Tkinter

Python Tkinter je standardna Python biblioteka za izradu grafičkog korisničkog sučelja. Biblioteka „Tkinter“ omogućava jednostavnu izradu desktop aplikacija s funkcionalnim grafičkim sučeljima. U projektu Tkinter je korišten za prikaz korisničkog sučelja kroz forme gdje korisnici mogu dodavati, pregledavati i mijenjati igrače u timu. Također, sve komunicira s PostgreSQL bazom putem biblioteke „psycopg2“.


3. Opis aplikacijske domene

Korisnici ovog sustava su ljubitelji nogometa koji žele sudjelovati u Fantasy ligama kao virtualni menadžeri. Štoviše, sustav omogućava korisnicima da budu menadžeri, odnosno da sastave vlastiti tim od stvarnih nogometaša, upravljaju igračima te prate njihov uspjeh na temelju sportskih rezultata.

Korisnici sustav koriste za pregled dostupnih igrača koji su iz različitih zemalja i pozicija. Osim toga, dodaju željene nogometaše u svoj tim, ali i uklanjaju one koji im ne odgovaraju. Preko sustava omogućeno im je praćenje budžeta što igra ulogu u samim pravilima Fantasy lige.

Na kraju, sustav pomaže korisnicima (virtualnim menadžerima) upravljati timom, praćenjem cijena i brzih, ali jednostavnih promjena sastava. Takav način rada je pogodan jer štedi vrijeme i smanjuje mogućnost pogreške pri odabiru njihovih igrača. Informacijski sustav „Fantasy lige“ je koristan za sve fanatike nogometa koji žele aktivno sudjelovati i poduprijeti svoj tim ili igrača, a to povećava konkurentnost u sudjelovanju.

4. Prikaz i razrada ERA modela



Slika 1: ERA dijagram, autorski rad

ERA model prikazuje srž i strukturu baze podataka za ovaj sustav. Glavni fokus ovog ERA modela je na korisničke timove, igrače te njihov izbor u korisničkom timu. ERA model se sastoji od deset tablica sa svojim atributima te primarnim, odnosno stranim ključevima.

Tablica *korisnik* predstavlja korisnike samog sustava. Sadrži njegov primarni ključ (*id_korisnika*) te attribute koji su bitni za korisnikovu registraciju u sustav (ime, prezime, e-mail adresa). Nadalje, tablica *liga* opisuje fantasy nogometne lige, odnosno svojim atributima specificira naziv lige, sezonu i datum kreiranja. Tablica *kolo* predstavlja pojedino kolo natjecanja unutar lige te povezuje kolo sa odgovarajućom fantasy ligom.

Zatim, tablica *tim_od_korisnika*, kako i ime kaže, predstavlja fantasy tim kojeg je korisnik, odnosno virtualni menadžer odabrao. Sadrži attribute koji predstavljaju naziv korisnikovog tima, pozicije u ligi te ukupne osvojene bodove.

Tablica *nog_klub* predstavlja stvarne nogometne klubove čiji igrači sudjeluju u fantasy sustavu. Naziv kluba te država iz koje potječe klub su atributi tablice. Isto tako, tablica *pozicija* definira mogućnost nogometnih pozicija igrača na terenu. Te tablice su strani ključevi u tablici *igrač* u kojem su stvarne osobe, odnosno nogometni igrači koji su dostupni na odabir korisnicima ili virtualnim menadžerima. U tablici su navedeni atributi ime i prezime igrača te njegov broj na dresu.

Nadalje, tablica *izbor_igraca* bilježi odabir igrača kojega je korisnik odabrao u svoj fantasy tim. Povezuje korisnika s odabranim igračem i pohranjuje poziciju na kojoj igrač igra.


Kroz tablice *pojednosti_kola* i *promjene* bilježe se statistički podatci o performansama igrača, odnosno o promjenama unutar korisnikova tima.

5. Primjer upita i okidača

5.1 Jednostavni upiti

5.1.1 Prvi primjer jednostavnog upita

Upit koji prikazuje sve igrače Real Madrida




```
294 ✓ SELECT ime, prezime, broj_dresa
295 FROM igrac
296 WHERE id_kluba = 1;
```

	ime	prezime	broj_dresa
1	Luka	Modrić	10
2	Vinicius	Junior	20
3	Thibaut	Courtois	1
4	Antonio	Rüdiger	22
5	Cristian	Ronaldo	4

Slika 2: Jednostavni upit 1, autorski rad

5.1.2 Drugi primjer jednostavnog upita

Upit koji prikazuje korisnike sortirane po prezimenu




```
298
299 ✓ SELECT ime, prezime, e_mail
300 FROM korisnik
301 ORDER BY prezime;
```

	ime	prezime	e_mail
1	Stjepan	Horvat	stjepan@gmail.com
2	Mateo	Kovačić	mateo@gmail.com
3	Antonio	Modrić	antonio@gmail.com

Slika 3: Jednostavni upit 2, autorski rad

5.1.3 Treći primjer jednostavnog upita

Upit koji prikazuje sve igrače koji imaju broj dresa veći od 10



```
374 ✓ SELECT ime, prezime, broj_dresa
375 FROM igrac
376 WHERE broj_dresa > 10
377 ORDER BY broj_dresa;
```

Output postgres.fantasy.igrac


	ime	prezime	broj_dresa
1	Mohamed	Salah	11
2	Mike	Maignan	16
3	Kevin	De Bruyne	17
4	Vinicius	Junior	20
5	Antonio	Rüdiger	22
6	Thomas	Müller	25
7	Ederson	Moraes	31
8	Stjepan	Marić	45
9	Gianluigi	Donnarumma	99

Slika 4: jednostavni upit 3, autorski rad

5.2 Složeni upiti

5.2.1 Prvi primjer složenog upita

Upit koji prikazuje sve igrače sa njihovim klubovima



```
304 ✓ SELECT i.ime, i.prezime, i.broj_dresa, nk.naziv_kluba, nk.drzava
307 FROM igrac i
308 INNER JOIN nog_klub nk ON i.id_kluba = nk.id_kluba
309 ORDER BY nk.naziv_kluba;
```


Output Result 5

	ime	prezime	broj_dresa	naziv_kluba	drzava
1	Rafael	Leão	10	AC Milan	Italija
2	Mike	Maignan	16	AC Milan	Italija
3	Pedri	González	8	Barcelona	Španjolska
4	Marc-André	ter Stegen	1	Barcelona	Španjolska
5	Robert	Lewandowski	9	Barcelona	Španjolska
6	Thomas	Müller	25	Bayern München	Njemačka
7	Leroy	Sané	10	Bayern München	Njemačka
8	Manuel	Neuer	1	Bayern München	Njemačka
9	Dusan	Vlahović	9	Juventus	Italija
10	Mohamed	Salah	11	Liverpool	Engleska
11	Virgil	van Dijk	4	Liverpool	Engleska
12	Erling	Haaland	9	Manchester City	Engleska
13	Kevin	De Bruyne	17	Manchester City	Engleska
14	Ederson	Moraes	31	Manchester City	Engleska
15	Gianluigi	Donnarumma	99	PSG	Francuska
16	Kylian	Mbappé	7	PSG	Francuska
17	Cristian	Ronaldo	4	Real Madrid	Španjolska
18	Vinicius	Junior	20	Real Madrid	Španjolska
19	Thibaut	Courtois	1	Real Madrid	Španjolska
20	Antonio	Rüdiger	22	Real Madrid	Španjolska
21	Luka	Modrić	10	Real Madrid	Španjolska

Slika 5: Složeni upit 1, autorski rad

5.2.2 Drugi primjer složenog upita

Upit koji prikazuje igrače po broju postignutih golova



The screenshot shows a SQL query in a dark-themed editor. The query is a SELECT statement that joins several tables: 'pojedinnost_kola' (pk), 'izbor_igraca' (iz), 'igrac' (i), and 'nog_klub' (nk). It calculates the total goals scored by each player (SUM(pk.golovi) AS ukupno_golova) and orders the results by the number of goals in descending order (ORDER BY ukupno_golova DESC).

```
311
312 ✓ SELECT
313     i.ime,
314     i.prezime,
315     nk.naziv_kluba,
316     SUM(pk.golovi) AS ukupno_golova
317 FROM pojedinnost_kola pk
318 INNER JOIN izbor_igraca iz 1.n<->1: ON pk.id_izbora = iz.id_izbora
319 INNER JOIN igrac i 1.n<->1: ON iz.id_igraca = i.id_igraca
320 INNER JOIN nog_klub nk 1.n<->1: ON i.id_kluba = nk.id_kluba
321 GROUP BY i.ime, i.prezime, nk.naziv_kluba
322 ORDER BY ukupno_golova DESC;
```


Below the query, the 'Output' tab shows 'Result 10' with a table of 7 rows and 5 columns: ime, prezime, naziv_kluba, and ukupno_golova.

	ime	prezime	naziv_kluba	ukupno_golova
1	Kevin	De Bruyne	Manchester City	3
2	Vinicius	Junior	Real Madrid	2
3	Mohamed	Salah	Liverpool	2
4	Thomas	Müller	Bayern München	1
5	Luka	Modrić	Real Madrid	0
6	Thibaut	Courtois	Real Madrid	0
7	Manuel	Neuer	Bayern München	0

Slika 6: Složeni upit 2, autorski rad

5.2.3 Treći primjer složenog upita

Upit koji prikazuje kompletne postavbe tima



The screenshot shows a SQL query in a dark-themed editor. The query is a SELECT statement that joins several tables: 'izbor_igraca' (ig), 'tim_od_korisnika' (tk), 'igrac' (i), 'nog_klub' (nk), and 'pozicija' (p). It filters for the team 'HORVAT ALL STARS' (WHERE tk.id_tima = 1) and orders the results by the player's position (ORDER BY ig.pozicija_u_postavi).

```
379 ✓ SELECT
380     tk.naziv_tima,
381     ig.pozicija_u_postavi AS pozicija,
382     i.ime || ' ' || i.prezime AS igrac,
383     nk.naziv_kluba,
384     p.naziv_pozicije,
385     ig.cijena
386 FROM izbor_igraca ig
387 INNER JOIN tim_od_korisnika tk 1.n<->1: ON ig.id_tima = tk.id_tima
388 INNER JOIN igrac i 1.n<->1: ON ig.id_igraca = i.id_igraca
389 INNER JOIN nog_klub nk 1.n<->1: ON i.id_kluba = nk.id_kluba
390 INNER JOIN pozicija p 1.n<->1: ON i.id_pozicije = p.id_pozicije
391 WHERE tk.id_tima = 1
392 ORDER BY ig.pozicija_u_postavi;
```

Below the query, the 'Output' tab shows 'Result 12' with a table of 5 rows and 6 columns: naziv_tima, pozicija, igrac, naziv_kluba, naziv_pozicije, and cijena.

	naziv_tima	pozicija	igrac	naziv_kluba	naziv_pozicije	cijena
1	HORVAT ALL STARS		1 Luka Modrić	Real Madrid	Veznjaci	12.00
2	HORVAT ALL STARS		2 Vinicius Junior	Real Madrid	Napadači	14.00
3	HORVAT ALL STARS		3 Thibaut Courtois	Real Madrid	Golman	8.00
4	HORVAT ALL STARS		4 Robert Lewandowski	Barcelona	Napadači	15.00
5	HORVAT ALL STARS		5 Pedri González	Barcelona	Veznjaci	10.00

Slika 7: Složeni upit 3, autorski rad

5.3 Okidači

5.3.1 Prvi primjer okidača

Ovaj okidač automatski izračunava poene igrača na temelju golova, asistencija i odigranih minuta prije unosa ili ažuriranja podataka

```
CREATE OR REPLACE FUNCTION fn_izracun_poena()
RETURNS TRIGGER AS $$
BEGIN
    IF NEW.minute_odigrane >= 60 THEN
        NEW.poeni := (NEW.golovi * 5) + (NEW.asistencije * 3) + 2;
    ELSE
        NEW.poeni := (NEW.golovi * 5) + (NEW.asistencije * 3);
    END IF;
    RETURN NEW;
END;
$$ LANGUAGE plpgsql;

CREATE TRIGGER tr_izracun_poena
BEFORE INSERT OR UPDATE ON pojednost_kola
FOR EACH ROW
EXECUTE FUNCTION fn_izracun_poena();
```

Slika 8: Okidač 1, autorski rad

5.3.2 Drugi primjer okidača

Ovaj okidač provjerava da tim ne može imati više od 11 igrača prije dodavanja novog igrača u postavu.

```
CREATE OR REPLACE FUNCTION fn_provjera_broja_igraca()
RETURNS TRIGGER AS $$
DECLARE
    broj_igraca INTEGER;
BEGIN
    SELECT COUNT(*)
    INTO broj_igraca
    FROM izbor_igraca
    WHERE id_tima = NEW.id_tima;

    IF broj_igraca >= 11 THEN
        RAISE EXCEPTION 'Tim može imati maksimalno 11 igrača!';
    END IF;

    RETURN NEW;
END;
$$ LANGUAGE plpgsql;

CREATE TRIGGER tr_provjera_broja_igraca
BEFORE INSERT ON izbor_igraca
FOR EACH ROW
EXECUTE FUNCTION fn_provjera_broja_igraca();
```


Slika 9: Okidač 2, autorski rad

6. Prikaz funkcionalnosti razvijenog sučelja

Prikaz funkcionalnosti korisničkog sučelja na primjeru dviju formi za sustav upravljanja fantasy nogometne lige. Korisničko sučelje služi za dodavanje i uređivanje igrača unutar Fantasy sustava. Za izradu formi korišten je Python Tkinter, čime je postignuto radno okruženje za desktop aplikaciju. Početna forma sadrži tri gumba koji omogućuju različite funkcije. Gumb „Spoji se na bazu“, korisniku omogućuje direktno spajanje na bazu te započinjanje procesa dodavanja, uređivanja ili pregleda, ovisno o korisnikovoj namjeri. Ukoliko se korisnik ne spoji na bazu, već želi odmah upravljati, sustav javlja grešku. Nakon uspješnog spajanja, korisnik odabire između dvije opcije. Upravljanje igračima ili pregleda statistike, odnosno poredak timova. Ulaskom u formu jedan, upravljanje igračima, korisniku se otvara forma u kojoj ima mogućnost vidjeti sve igrače te njihove atribute (klub, dres, ime, prezime), ali i mogućnosti uređivanja. Korisnik može sam dodati novog igrača, izmijeniti podatke postojećeg te obrisati postojećeg. Nadalje, otvaranjem druge forme, poredak timova, korisnik ima jasan uvid u točan poredak timova te njihov broj bodova.



Slika 10: Forma sučelja 1, autorski rad



Slika 11: Forma sučelja 2, autorski rad

1 - Upravljanje igračima

Upravljanje igračima

Ime:

Prezime:

Broj Dres:

Klub:

ID	Ime	Prezime	Klub	Dres
13	Erling	Haaland	Manchester City	9
14	Kevin	De Bruyne	Manchester City	17
15	Ederson	Moraes	Manchester City	31
16	Mohamed	Salah	Liverpool	11
17	Virgil	van Dijk	Liverpool	4
18	Dusan	Vlahović	Juventus	9
19	Rafael	Leão	AC Milan	10
20	Mike	Maignan	AC Milan	16
21	Cristian	Ronaldo	Real Madrid	4
22	Stjepan	Marić	Liverpool	45

Slika 12: Forma sučelja 3, autorski rad

2 - Poredak Timova

Poredak timova

Naziv Tima	Ukupni Bodovi
MODRIĆ SQUAD	32
HORVAT ALL STARS	19
WORLD CUP DREAMERS	18

Slika 13: Forma sučelja 4, autorski rad

7. Zaključak

Izrada informacijskog sustava za fantasy nogometnu ligu omogućila mi je uvid u detaljan pregled i razumijevanje postupaka vezanih uz vođenje virtualnih momčadi, igrača te upravljanjem podacima. Nadalje, ERA model pokazuje kako su tablice povezane što olakšava izradu same baze, ali i korisničkog sučelja jer jasno prikazuje međusobnu povezanost unutar aplikacije. Isto tako, korištenjem DataGripa dodatno je olakšano testiranje ispravnosti aplikacije i rješenja upita.

Pomoću Python Tkinter biblioteke unos podataka unutar sustava je jednostavno i dodatno olakšava radnju korisniku. Kroz izradu projekta napravljene su temeljne funkcije za stvaranje, čitanje, ažuriranje i brisanje zapisa, odnosno igrača. Kombinacijom relacijskih baza s korisničkim sučeljem znatno se smanjuje greška u obradi informacija, uz istovremeno brže dohvaćanje sadržaja.

Ovaj projekt omogućuje proširenje u kasnijim fazama, gdje bi se dodale naprednije funkcionalnosti, poput automatskog ažuriranja cijena. S druge strane, razvoj ovog sustava omogućio je usvajanje te uvid u koncepte relacijskih baza u stvarnom životu te njihovu primjenu kroz obradu teme koja kombinira sportski interes s tehničkim znanjem.

Popis literature

- [1] M. Maleković, K. Rabuzin, *Uvod u baze podataka*, Varaždin: Fakultet organizacije i informatike, Sveučilište u Zagrebu, 2016.
- [2] Draw.io - Free Online Diagram Software. (bez dat.). Pristupano 16. siječnja, 2025., sa <https://www.diagrams.net/>
- [3] PostgreSQL: The World's Most Advanced Open Source Relational Database. (bez dat.). Pristupano 16. siječnja, 2025., sa <https://www.postgresql.org/>
- [4] Python Software Foundation. (bez dat.). Python Documentation. Pristupano 16. siječnja, 2025., sa <https://docs.python.org/3/>
- [5] Tkinter - Python interface to Tcl/Tk. (bez dat.). Pristupano 16. siječnja, 2025., sa <https://docs.python.org/3/library/tkinter.html>

Popis slika

Slika 1: ERA dijagram, autorski rad	4
Slika 2: Jednostavni upit 1 , autorski rad	5
Slika 3: Jednostavni upit 2 , autorski rad	5
Slika 4: jednostavni upit 3, autorski rad	6
Slika 5: Složeni upit 1 , autorski rad	6
Slika 6: Složeni upit 2 , autorski rad	7
Slika 7: Složeni upit 3, autorski rad	7
Slika 8: Okidač 1 , autorski rad	8
Slika 9: Okidač 2 , autorski rad	8
Slika 10: Forma sučelja 1, autorski rad	9
Slika 11: Forma sučelja 2, autorski rad	9
Slika 12: Forma sučelja 3, autorski rad	10
Slika 13: Forma sučelja 4, autorski rad	10